



Fundamentos de IA: RAG e Hugging Face

Explorando Retrieval-Augmented Generation na prática com Python

Aula de IA - Semana #8 | Atividade Prática

| O Problema: Alucinações de IA



Limitação de Dados

Modelos de linguagem (LLMs) são treinados com dados estáticos. Eles não conhecem eventos que ocorreram após sua data de corte ou documentos privados de uma empresa.



Alucinações


Quando uma LLM não possui a informação correta, ela tende a gerar respostas que parecem convincentes, mas são factualmente incorretas ou inventadas.

| A Solução: O que é RAG?

Retrieval-Augmented Generation (RAG) é uma técnica que permite à IA consultar uma fonte de conhecimento externa antes de gerar uma resposta.

- **Recuperar:** Busca informações relevantes em um documento ou base de dados.
- **Aumentar:** Insere esse contexto na pergunta do usuário.
- **Gerar:** A IA cria a resposta baseada estritamente no contexto fornecido.

Diagrama da arquitetura RAG



Implementação

Pipeline do Hugging Face

Utilizamos a biblioteca `transformers` e o modelo **RoBERTa** treinado no dataset SQuAD2.0.

- **Modelo:** `deepset/roberta-base-squad2`
- **Contexto:** Dados sobre a Hugging Face
- **Resultado:** Resposta precisa baseada no texto, sem alucinações.



Execução concluída com sucesso!

| Image Sources



Thumbnail

https://miro.medium.com/1*3--ogs382NaIU2v3LfVVcQ.png

Source: medium.com

for

medium.com



Thumbnail

<https://camo.githubusercontent.com/774eefdc490eba54630491d3dc58232c5a7ae35e1930003771ee8d19363aa388/68747470733a2f2f68756767696e676666163652e636f2f64617461736574732f68756767696e676666163652f646f63756d656e746174696f6e2d696d616765732f7265736f6c76652f6d61696e2f736d6f6c6167656e74732f736d6f6c6167656e74732e706e67>

Source: github.com

for

github.com